

Kamień milowy 1

Klaudia Gruszkowska, Bartosz Jamroży, Grzegorz Kiersnowski

May 15, 2022

ADAPTIVE TRANSFER LEARNING: A SIMPLE BUT EFFECTIVE TRANSFER LEARNING (Jung H Lee, Henry J Kvinge, Scott Howland, Zachary New, John Buckheit, Lauren A. Phillips, Elliott Skomski, Jessica Hibler, Courtney D. Corley, Nathan O. Hodas)

Data publikacji preprintu: 23 listopad 2021


Artykuł opisuje podejście adaptive transfer learning, które jest odpowiedzialne za wybór optymalnych feature-maps dla transfer-learningu.

Jak omawiane rozwiązanie wpisuje się w całą dziedzinę?

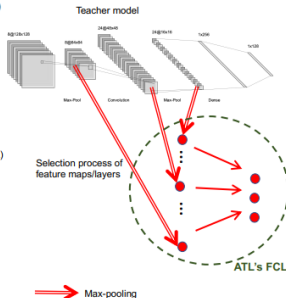
Realizacja transfer-learningu na której bazuje wybrane przez nas podejście to strojenie cech modelu dużego (nauczyciela) na nowym zbiorze danych. Podejście klasyczne ma 3 wersje: jedynie ostatnia warstwa, kilka ostatnich warstw albo wszystkie warstwy są strojone na nowym zbiorze. Jednak nie zawsze ostatnie warstwy są najlepszym wyborem do strojenia.

Autorzy artykułu postanowili odpowiedzieć na pytanie : w jaki sposób wybrać najlepsze cechy do strojenia modelu na nowym zbiorze danych(students model)? Postawili hipotezę, że najlepsze cechy powinny selektywnie odpowiadać na klasy zadań docelowych. Postanowili oszacować, jak dobrze wyjścia warstw są grupowane według wejść.

A Conventional FT/TL




B Adaptive Transfer Learning



Obrazek powyżej przedstawia porównanie konwencjonalnego strojenia wag dla transfer learningu a podejścia wykorzystującego adaptive transfer learning.

Jakie architektury beda analizowane?

ResNet - wykorzystuje pomijanie lub skróty do przeskakiwania niektórych warstw. Typowe modele ResNet sa implementowane z dwu- lub trzywarstwowymi pominięciami, które zawieraja nieliniowości (ReLU) i normalizacje wsadowa pomiedzy nimi.



Planowane działania

- ▶ Implementacja architektury opisanej w artykule.
- ▶ Testowanie czy zaimplementowane rozwiązanie uzyskuje zbliżone wyniki do tych podanych w artykule. Bedziemy bazować na zbiorze danych ImageNet, który został użyty przez autorów.
- ▶ Przygotowanie oraz testowanie działania algorytmu na danych medycznych. Planujemy wykorzystać zbiór danych PCAM.
- ▶ Napisanie artykułu. Opis wykonanego przez nas rozwiązania oraz porównanie.

Harmonogram prac

- ▶ 7.04 - kamień milowy 1a
- ▶ 10.04 - zebranie opisów artykułów
- ▶ 14.04 - kamień milowy 1b
- ▶ 14.04 - 30.04 - implementacja i testowanie
- ▶ 30.04 - 05.05 - testowanie na danych medycznych
- ▶ 5.05 - kamień milowy 2
- ▶ 5.05 - 22.05 - przygotowanie artykułu

Podział obowiązków

- ▶ Latex - Klaudia
- ▶ implementacja - Klaudia, Bartek, Grzesiek
- ▶ testowanie - Bartek, Grzesiek
- ▶ testowanie na danych medycznych - Klaudia, Bartek
- ▶ artykuł - Klaudia (wstęp, abstract), Bartek (część implementacyjna), Grzesiek(część graficzna, zakończenie)
- ▶ prezentacja - Klaudia, Bartek
- ▶ nagranie - Grzesiek

Narzedzia i dane

- ▶ Pytorch
- ▶ ImageNet ,CUB_200_2011 , FGVC-Aircraft , CIFAR100 , Fruits_360 and Omniglot a później spróbujemy wykorzystać dane medyczne (PCAM)