

Warsztaty badawcze 2022

Klaudia Gruszkowska

Bartosz Jamróży

Grzegorz Kiersnowski

15 maja 2022

1 Literatura

Deep learning jest w ostatnim czasie intensywnie rozwijającą się dziedziną przetwarzania danych [6]. Możemy posłużyć się nim między innymi do klasyfikacji skomplikowanych danych np. danych obrazowych. Jednakże jest to dziedzina wymagająca złożonych obliczeń. Rzadko dysponuje się tak dużymi mocami obliczeniowymi oraz wystarczająco obszernymi zbiorami danych, potrzebnymi do wytrenowania modeli. Dlatego chcielibyśmy móc w pewien sposób bazować na już wstępnie wytrenowanych modelach (nie tylko samych architekturach ale także na wyznaczonych wagach). Rozwiązaniem tego problemu jest transfer learning. Jest to dziedzina silnie rozwojowa, nieustrukturyzowana, o sporej ilości nowych koncepcji. Jedną z nich jest adaptive transfer learning [7].

W naszej pracy chcemy zaimplementować to podejście oraz odtworzyć wyniki z artykułu [7]. Autorzy bazują w nim na modelu ResNet50 [2] trenowanym na zbiorze ImageNet [1] [3]. Dodatkowo testują rezultaty wykorzystania tego podejścia również w pracy na zbiorach: (CUB_200_2011 [11], FGVC-Aircraft [8], CIFAR100 [4], Fruits_360 [10] i Omniglot [5]).

Praktyczna dziedzina, w której można stosować przetwarzanie obrazów są problemy medyczne. Często nie dysponujemy wystarczającą ilością sklasyfikowanych danych by trenować model od podstaw. Taka ręczna klasyfikacja wymaga wiedzy specjalistycznej co wiąże się z wysokim kosztem. Dlatego też szczególnie w tej dziedzinie często ma zastosowanie transfer learning [9]. W naszym przypadku zaimplementowane rozwiązanie wykorzystamy do testowania klasyfikacji na danych medycznych PCAM.

Literatura

- [1] Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. Imagenet: A large-scale hierarchical image database. In *2009 IEEE Conference on Computer Vision and Pattern Recognition*, pages 248–255, 2009.
- [2] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778, 2016.
- [3] Minyoung Huh, Pulkit Agrawal, and Alexei A. Efros. What makes imagenet good for transfer learning?, 2016.
- [4] Alex Krizhevsky, Geoffrey Hinton, et al. Learning multiple layers of features from tiny images. 2009.
- [5] Brenden M Lake, Ruslan Salakhutdinov, and Joshua B Tenenbaum. Human-level concept learning through probabilistic program induction. *Science*, 350(6266):1332–1338, 2015.
- [6] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. Deep learning. *nature*, 521(7553):436–444, 2015.

- [7] Jung H Lee, Henry J Kvinge, Scott Howland, Zachary New, John Buckheit, Lauren A. Phillips, Elliott Skomski, Jessica Hibler, Courtney D. Corley, and Nathan O. Hodas. Adaptive transfer learning: a simple but effective transfer learning, 2021.
- [8] Subhransu Maji, Esa Rahtu, Juho Kannala, Matthew Blaschko, and Andrea Vedaldi. Fine-grained visual classification of aircraft. *arXiv preprint arXiv:1306.5151*, 2013.
- [9] Mohammad Amin Morid, Alireza Borjali, and Guilherme Del Fiol. A scoping review of transfer learning research on medical image analysis using imagenet. *Computers in Biology and Medicine*, 128:104115, 2021.
- [10] Horea Mureşan and Mihai Oltean. Fruit recognition from images using deep learning. *arXiv preprint arXiv:1712.00580*, 2017.
- [11] Catherine Wah, Steve Branson, Peter Welinder, Pietro Perona, and Serge Belongie. The caltech-ucsd birds-200-2011 dataset. 2011.